UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS

Fundada en 1551

FACULTAD DE INGENIERÍA DE SISTEMAS E INFORMÁTICA

ESCUELA PROFESIONAL DE INGENIERÍA DE SOFTWARE - LIMA



Compresión del Negocio

Grupo 12

Integrantes:

De la Cruz Aguilar Gabriel Sonny

Arevalo Mauricio Diego Martin

Chicata Serrato Sebastian Joaquin

Piñarreta Rojas David Sebastian

Bayona Vera Ashley Elizabeth

Docente:

Pedro Martín Lezama Gonzales

Asignatura:

Minería de Datos

1. INFORMACIÓN DE LA EMPRESA

1.1 ESTRUCTURA DE LA ORGANIZACIÓN

A) Junta Directiva (Board of Directors)

- Director Ejecutivo (CEO): Radek Pluhař (CEO histórico de Home Credit Group).

- Director de Riesgos (CRO - Chief Risk Officer): Martin Dvořák (Responsable global de la mitigación de impagos).

- Director de Datos y Analítica (CDO): Elena Volkova (Supervisora de la infraestructura de minería de datos).

B) Divisiones Corporativas y Departamentos

- División de Gestión de Riesgos: Departamento de Aprobación Automática (Underwriting) y Departamento de Cobranzas Tempranas.

- **División de Ciencia de Datos y TI:** Grupo de Minería de Datos (tu equipo) y Arquitectura de Datos Alternativos.

- **División Comercial:** Expansión de Inclusión Financiera y Atención al Cliente.

1.2 INDIVIDUOS CLAVE DE LA ORGANIZACIÓN

- Radek Pluhař (CEO): Define la visión estratégica de ampliar la inclusión financiera para la población no bancarizada, asegurando que el negocio crezca de manera sostenible.

- Martin Dvořák (CRO): Establece los umbrales de riesgo aceptables y es el principal interesado en reducir la tasa actual del 8% de morosidad.

- Líder Técnico de Minería de Datos: Tu rol en el proyecto, responsable de traducir los datos transaccionales y de telecomunicaciones en un modelo predictivo CRISP-DM.

1.3 PATROCINADOR INTERNO (SPONSOR)

El **Director de Riesgos (CRO, Martin Dvořák)** fungirá como el patrocinador interno. Al ser el departamento que absorbe las pérdidas por créditos impagos, Riesgos proporcionará el presupuesto para la infraestructura computacional y la experiencia de dominio necesaria para interpretar variables complejas provenientes de burós externos y datos de telecomunicaciones.

1.4 COMITÉ DE DIRECCIÓN (STEERING COMMITTEE)

El proyecto será supervisado por un comité diseñado para alinear la tecnología con la rentabilidad:

- Radek Pluhař (CEO)

- Martin Dvořák (CRO)

- Elena Volkova (CDO)

- Director Financiero (CFO)

1.5 UNIDADES DE NEGOCIO AFECTADAS POR EL PROYECTO

Departamento de Evaluación de Créditos (Underwriting): Transformarán su flujo de trabajo al pasar de revisiones manuales a recibir una probabilidad de impago automatizada para cada cliente sin historial tradicional.

Departamento de Cobranzas: Recibirán una cartera de préstamos más sana, reduciendo la necesidad de operaciones de recuperación agresivas.

Servicio al Cliente: Podrán ofrecer respuestas de aprobación o rechazo de manera casi instantánea, mejorando la experiencia de endeudamiento del cliente.

2. ÁREA PROBLEMÁTICA

2.1 IDENTIFICACIÓN DEL ÁREA PROBLEMÁTICA

El área problemática principal corresponde a la **Gestión de Riesgos Financieros (Risk Management)** y específicamente al departamento de **Evaluación de Créditos (Underwriting)**. Secundariamente, impacta al área de Atención al Cliente, ya que el proceso de evaluación determina la experiencia inicial del usuario.

2.2 DESCRIPCIÓN DEL PROBLEMA DE FORMA GENERAL

Gran parte de la población mundial tiene dificultades para obtener préstamos tradicionales debido a historiales crediticios insuficientes o inexistentes (población no bancarizada). El problema radica en que, sin un historial clásico, las entidades financieras no pueden calcular con precisión la probabilidad de reembolso. Esto genera dos escenarios perjudiciales: el rechazo injusto de clientes que sí tienen la capacidad económica para pagar (pérdida de negocio y exclusión financiera) y la aprobación de créditos a clientes insolventes (que genera la tasa de morosidad actual del 8% y grandes pérdidas para la empresa).

2.3 REQUISITOS PREVIOS, MOTIVACIONES Y SITUACIÓN ACTUAL DE LA MINERÍA DE DATOS

- Requisitos previos: La iniciativa exige la recolección, consolidación y capacidad de procesamiento de fuentes alternativas de información (datos transaccionales, hábitos de pago parcelados e interacciones de telecomunicaciones) centralizadas dentro de una arquitectura relacional (compuesta por los 8 insumos CSV provistos).

- Motivaciones: El propósito fundamental reside en promover la inclusión financiera mediante un proceso crediticio transparente y confiable. Se busca evitar la denegación innecesaria a postulantes solventes, asignando montos adecuados junto con cronogramas de amortización ajustados a sus posibilidades reales.

- Uso actual de minería de datos: Efectivamente, Home Credit emplea enfoques estadísticos y modelos iniciales de machine learning para sus estimaciones. No obstante, esta propuesta apunta a optimizar dichos esquemas para extraer el máximo valor explicativo presente en los atributos no estructurados.

2.4 ESTADO DEL PROYECTO DE MINERÍA DE DATOS EN EL CASO DE NEGOCIO

El esfuerzo técnico ya ha sido aprobado por la Dirección de Riesgos como una iniciativa estratégica para reducir el incumplimiento. Sin embargo, **es necesario "publicitarlo"** activamente ante las divisiones Comerciales y de Atención al Cliente como una "tecnología clave para el negocio". Se debe comunicar que este modelo predictivo no es un filtro restrictivo para denegar más créditos, sino una herramienta de precisión que automatizará las aprobaciones, reducirá los tiempos de espera y aumentará la base de clientes seguros.

3. DESCRIPCIÓN DE LA SOLUCIÓN ACTUAL

Actualmente, Home Credit aborda el problema de la evaluación de riesgo crediticio utilizando una combinación de **sistemas basados en reglas rígidas (heurísticas)** y procesos de **evaluación manual (Underwriting tradicional)**. Cuando un cliente solicita un préstamo, el sistema evalúa su perfil aplicando filtros estáticos básicos (ej. umbrales mínimos de ingresos, cruce con burós de crédito tradicionales si existen, y estado laboral).

Si el cliente carece de historial crediticio (población no bancarizada), su solicitud pasa a una revisión manual donde los analistas de crédito evalúan la documentación adjunta. Aunque la empresa ha empezado a implementar métodos estadísticos rudimentarios para apoyar estas decisiones, la solución actual sigue dependiendo en gran medida de reglas de exclusión directas en lugar de un análisis predictivo integral basado en datos alternativos (como comportamiento de telecomunicaciones o historial de vivienda).

3.1 VENTAJA Y DESVENTAJA DE LA SOLUCIÓN ACTUAL

3.1.1 VENTAJAS

- Alta explicabilidad (Interpretabilidad): Es muy fácil para un asesor de servicio al cliente explicar el motivo de un rechazo (ej. "Sus ingresos declarados no alcanzan el umbral mínimo para este monto").

- Cumplimiento regulatorio directo: Al basarse en reglas estáticas, el proceso es completamente transparente para auditorías financieras tradicionales.

- Familiaridad operativa: El personal actual de evaluación y atención al cliente está completamente capacitado en este flujo de trabajo estándar.

3.1.2 DESVENTAJAS

- **Incapacidad de escalar (Cuello de botella):** La revisión manual o semi-automatizada no es suficiente para procesar cientos de miles de solicitudes en tiempo real.

- **Pérdida de patrones ocultos:** Los sistemas de reglas rígidas no pueden detectar relaciones complejas y no lineales (por ejemplo, cómo interactúa la antigüedad en el empleo con el tipo de vivienda y el historial de transacciones previas para predecir el pago).

- **Alta tasa de falsos negativos y exclusión:** Al no saber cómo interpretar correctamente los "datos alternativos", el sistema actual rechaza injustamente a muchos clientes que sí tienen capacidad de pago pero carecen de historial tradicional.

- **Pérdidas financieras sostenidas:** A pesar de los filtros manuales, la tasa de morosidad se mantiene en un problemático ~8%, lo que representa millones en pérdidas operativas.

3.2 NIVEL DE ACEPTACIÓN DE LA SOLUCIÓN DE LA ORGANIZACIÓN

El nivel de aceptación de la solución actual está altamente polarizado. A **nivel operativo** (analistas de crédito y atención al cliente), el sistema es aceptado por inercia, ya que es el estándar de trabajo al que están acostumbrados y confían en las reglas predefinidas.

Sin embargo, a **nivel directivo y gerencial** (Comité de Dirección y Patrocinadores del Proyecto), existe una **alta insatisfacción**. Los directivos son conscientes de que el método actual está frenando el crecimiento comercial (al rechazar buenos clientes) y generando un riesgo financiero inaceptable por los impagos. Por lo tanto, aunque la solución actual se mantiene en pie por necesidad operativa, la organización está sumamente receptiva e impulsando activamente la transición hacia una solución basada en Minería de Datos.

4. DEFINICIÓN DE LOS OBJETIVOS DE NEGOCIO

4.1 DESCRIPCIÓN DEL PROBLEMA QUE SE DESEA RESOLVER MEDIANTE LA MINERÍA DE DATOS

El problema central a resolver es la alta tasa de morosidad (aproximadamente 8%) y el ineficiente proceso de evaluación de riesgo crediticio para clientes pertenecientes a la población no bancarizada. El sistema actual basado en reglas manuales no logra calcular con precisión la capacidad de pago de personas sin historial crediticio tradicional. Mediante la minería de datos,

se busca descubrir patrones predictivos complejos y no lineales ocultos en fuentes de datos alternativas (historial transaccional previo, comportamiento de pagos en cuotas, y datos de telecomunicaciones) para identificar qué solicitantes son financieramente confiables.

4.2 ESPECIFICACIONES DE LAS CUESTIONES DEL NEGOCIO

Para abordar este problema, el análisis de minería de datos deberá responder de forma específica a las siguientes preguntas críticas del negocio:

- ¿Cuál es la probabilidad matemática exacta de que un solicitante específico incurra en un impago durante el ciclo de vida de su préstamo?

- ¿Qué variables de datos alternativos tienen el mayor poder predictivo para perfilar a un buen pagador?

- ¿Qué perfiles demográficos o transaccionales que actualmente son rechazados por las reglas manuales poseen, en realidad, un bajo riesgo crediticio?

4.3 DETERMINACIÓN DE OTROS REQUISITOS DE NEGOCIO

Más allá de la precisión predictiva, la solución analítica debe cumplir con las siguientes restricciones y requerimientos operativos:

- **Interpretabilidad y Cumplimiento Normativo:** El modelo de evaluación no puede operar como una "caja negra". Debe ser capaz de explicar los factores principales detrás de una denegación de crédito para mantener la transparencia regulatoria y facilitar la labor de Atención al Cliente.

- **Mitigación de Sesgos:** Se debe garantizar que la utilización de datos alternativos (como características de la vivienda) no introduzca discriminación injusta hacia poblaciones vulnerables.

- **Eficiencia Operativa:** El modelo debe estar diseñado de forma que el cálculo de la probabilidad de impago (scoring) se ejecute en segundos para no afectar los tiempos de respuesta del negocio.

4.4 BENEFICIOS ESPERADOS EN TÉRMINOS DE NEGOCIO

La implementación exitosa de este proyecto de minería de datos proyecta los siguientes impactos cuantificables:

- Reducción del Riesgo Financiero: Disminuir la tasa global de morosidad mediante la identificación temprana de perfiles de alto riesgo (reduciendo la pérdida directa de capital).

- **Aumento de la Inclusión Financiera y Cuota de Mercado:** Incrementar el volumen de aprobaciones seguras al aceptar clientes con buen comportamiento transaccional que antes eran rechazados por falta de historial tradicional.

- **Optimización de Costos Operativos:** Reducir drásticamente la carga de trabajo del departamento de evaluación manual (Underwriting), permitiendo que el sistema apruebe o rechace automáticamente a la gran mayoría de los solicitantes basándose en sus umbrales de riesgo.

5. CRITERIOS DE RENDIMIENTO

5.1 CRITERIOS OBJETIVOS (CUANTITATIVAS)

Para medir el éxito técnico y comercial del modelo predictivo de forma precisa, se establecen los siguientes umbrales numéricos:

- **Poder Predictivo sobre el Desbalance:** Dado el extremo desbalance de clases (8% de morosos frente a 92% de pagadores), la precisión simple (Accuracy) no es un criterio válido. El rendimiento técnico se medirá utilizando la métrica **ROC-AUC**, exigiendo un valor mínimo de **0.75** en el conjunto de validación para garantizar que el modelo distingue eficazmente entre un buen y mal pagador.
- **Automatización Operativa:** El modelo debe ser capaz de procesar y emitir una recomendación automática (aprobar/rechazar) para al menos el **70% de las solicitudes entrantes**, derivando únicamente el 30% restante (casos atípicos o limítrofes) a revisión manual humana.
- **Contención de la Morosidad:** El portafolio de créditos aprobados por el modelo en entornos de simulación no debe exceder la tasa de pérdida máxima tolerable definida por el departamento de riesgos.

5.2 CRITERIOS SUBJETIVOS (CUALITATIVAS)

Para los aspectos que no se miden con un simple porcentaje, las expectativas de aceptación son las siguientes:

- **Interpretabilidad (White-box approach):** La evaluación subjetiva del modelo exigirá que este pueda generar un perfil explicativo. Cuando un cliente sea clasificado con "alto riesgo", el sistema debe poder listar los 3 o 5 factores principales que influyeron en esa decisión (ej. "alto índice de deudas previas" + "baja calificación en fuente externa 3").
- **Lógica de Negocio en Patrones Descubiertos:** Los clústeres o reglas que el modelo descubra usando "datos alternativos" deben tener sentido económico y social.
- **Toma de Decisión Final:** El criterio subjetivo definitivo recaerá en el **Director de Riesgos (CRO)**. Él y su comité evaluarán las variables más importantes (Feature

Importance) arrojadas por el modelo y determinarán si están alineadas con las políticas internas de Home Credit antes de autorizar cualquier despliegue a producción.

5.3 ALINEACIÓN DE TAREAS (CRITERIO vs OBJETIVO DE NEGOCIO)

Objetivo: Reducir el riesgo financiero → Criterio: ROC-AUC superior a 0.75.
Objetivo: Optimizar costos de evaluación manual → Criterio: Automatización del 70% del flujo de decisiones.
Objetivo: Interpretabilidad regulatoria → Criterio subjetivo: Aprobación de las reglas de negocio por parte del CRO.

6. INVENTARIO DE RECURSOS

6.1 RECURSOS DE HARDWARE

Se requiere una estación de trabajo o instancia de procesamiento (local o en la nube) con alta capacidad de memoria. Como se comprobó en el análisis preliminar, la lectura cruda de los archivos transaccionales secundarios consume más de 6.6 GB de RAM. Por lo tanto, el entorno de ejecución (Python/VS Code) exige un mínimo de **16 GB de RAM (idealmente 32 GB)** y un procesador multinúcleo para paralelizar los procesos de agrupación (Feature Engineering). Adicionalmente, se requieren al menos 15 GB de almacenamiento SSD libre para alojar los 2.6 GB de archivos .csv originales, los entornos virtuales y las exportaciones de datos procesados.

6.2 ORIGEN DE LOS DATOS Y ALMACENES DE CONOCIMIENTO

- Orígenes, tipos y formatos de datos: Los datos provienen de un volcado histórico anonimizado proporcionado por Home Credit. Están estructurados en **8 archivos planos en formato .csv** (Application, Bureau, Previous Applications, POS Cash, Installments, Credit Card Balance, y un diccionario de variables). Contienen datos tabulares de alta dimensionalidad (variables float64, int64 y category).
- Almacenamiento y acceso: Los archivos se encuentran almacenados de forma estática y local en la ruta del repositorio ../data/raw/. Al ser un extracto para modelado analítico, **no se dispone de acceso directo ni conexión en tiempo real a las bases de datos operativas (OLTP)** del banco, previniendo así cualquier riesgo de corromper los sistemas de producción.
- Adquisición de datos externos: No se requiere ni se ha planificado adquirir información demográfica o financiera externa adicional. El volcado de datos ya incluye las variables EXT_SOURCE_1, EXT_SOURCE_2 y EXT_SOURCE_3, las cuales representan calificaciones consolidadas e importadas previamente desde burós de crédito externos, siendo estas las variables predictivas más fuertes del proyecto.
- Problemas de seguridad: No existen barreras de seguridad críticas para acceder a la información, dado que Home Credit ya ha sometido el dataset a un proceso de desensibilización riguroso. Toda la Información de Identificación Personal (PII) ha sido eliminada y sustituida por llaves primarias enmascaradas (como SK_ID_CURR).

6.3 RECURSOS PERSONALES

Expertos y personal de apoyo: Para la ejecución técnica, se cuenta de forma exclusiva con el Líder Técnico de Minería de Datos, encargado de programar los flujos de limpieza, cruce relacional y modelado predictivo en Python. A nivel organizacional, el apoyo de validación de negocio proviene de la Dirección de Riesgos (expertos en el dominio financiero) y la provisión del volcado de datos fue gestionada por la Dirección de Datos.

Lista de contactos y recursos del informe:

- **Sebastian Chicata - Líder Técnico / Data Miner:** Responsable directo del procesamiento del dataset, entrenamiento de los algoritmos (XGBoost/LightGBM) y documentación metodológica CRISP-DM.
- **Martin Dvořák - Patrocinador / Director de Riesgos (CRO):** Validador de los resultados subjetivos del modelo, umbrales de riesgo aceptable y viabilidad comercial.
- **Elena Volkova - Directora de Datos (CDO):** Responsable de la auditoría técnica y proveedora del ecosistema de archivos .csv extraídos del Data Warehouse del banco.

7. REQUISITOS, SUPUESTOS Y RESTRICCIONES

7.1 DETERMINAR REQUISITOS

- Restricciones legales y de seguridad: El proyecto está sujeto a estrictas regulaciones de privacidad de datos financieros (como el GDPR en Europa y leyes locales de protección de datos personales). Como requisito innegociable, el modelo no debe intentar revertir el anonimato de los solicitantes ni utilizar variables demográficas protegidas que puedan generar sesgos discriminatorios.
- Alineación de planificación: Todos los actores técnicos y de negocio están alineados bajo el cronograma dictado por las seis fases secuenciales de la metodología CRISP-DM, priorizando la fase actual de comprensión y la inminente preparación de datos.
- Requisitos de despliegue: Los resultados no se desplegarán inicialmente como una interfaz web para el usuario final. El requisito técnico de despliegue es generar un pipeline automatizado (script por lotes o API) que reciba los datos del solicitante y devuelva la probabilidad matemática de impago directamente a la base de datos operativa del departamento de Evaluación (Underwriting).

7.2 DESCRIBIR LOS SUPUESTOS

- Factores económicos: Se asume que el costo computacional es el principal factor limitante. Dado el peso masivo del historial secundario (más de 6.6 GB de RAM en su estado crudo), el proyecto asume el riesgo de requerir optimización de código extrema o, en su defecto, la posible necesidad económica de rentar instancias de procesamiento en la nube si el hardware local resulta insuficiente.

- Calidad de datos: Se parte del supuesto de que el alto porcentaje de valores nulos descubiertos (hasta 70% en variables de vivienda) representa una "ausencia de información válida" (información implícita) y no un error informático de extracción. Se asume que técnicas algorítmicas avanzadas (como LightGBM o XGBoost) podrán manejar esta falta de datos sin requerir imputaciones artificiales que sesguen la realidad.
- Expectativas de visualización y comprensión: El comité de dirección (CRO y patrocinadores) no se conformará únicamente con visualizar un listado de "aprobados y rechazados". Exigen **comprender el modelo**. Esperan visualizar gráficos de Importancia de Características (Feature Importance) para entender exactamente qué pesos matemáticos está asignando el algoritmo a variables externas y transaccionales para justificar sus decisiones.

7.3 COMPROBAR LAS RESTRICCIONES

Acceso a los datos: Se dispone de acceso total y sin restricciones técnicas a la información. Todos los archivos .csv han sido descargados satisfactoriamente en el entorno virtual local (carpeta ../data/raw/), por lo que no se requieren contraseñas, VPNs o permisos de bases de datos adicionales para esta fase de modelado.
Restricciones legales comprobadas: Se ha comprobado que el uso de los datos es legalmente viable debido a que la institución ya aplicó un enmascaramiento estructural. Toda la Información de Identificación Personal (PII, por sus siglas en inglés) fue removida y reemplazada por identificadores alfanuméricos seguros (SK_ID_CURR, SK_ID_PREV), eliminando el riesgo de exposición de identidades.
Restricciones financieras presupuestadas: Al tratarse de una Prueba de Concepto (PoC) en fase de minería de datos, el presupuesto financiero se traduce actualmente en el límite de la capacidad computacional local. Las restricciones de hardware han sido mapeadas y se controlarán mediante técnicas de agregación de datos y manejo eficiente de memoria (gc.collect()) para evitar sobrecostos.

8. RIESGOS Y CONTINGENCIAS

Para anticipar posibles obstáculos durante el ciclo de vida del proyecto y asegurar su viabilidad, se han identificado las siguientes categorías de riesgo y sus respectivos planes de contingencia, tal como lo exige la metodología:

8.1 RIESGOS DE PROGRAMACIÓN (CRONOGRAMA)

Riesgo: La fase de Preparación de Datos (Feature Engineering) sobre las 6 tablas secundarias masivas puede exceder el tiempo planificado debido a cuellos de botella en el procesamiento local.
Plan de contingencia: Se procesarán los archivos mediante un enfoque secuencial por lotes (batch processing), guardando estados intermedios en disco. Si el tiempo apremia, se construirá y validará el modelo predictivo utilizando primero una muestra representativa del 10% del dataset antes de ejecutar el script completo.

8.2 RIESGOS FINANCIEROS

Riesgo: Saturación de la capacidad de hardware local (RAM) que obligue a rentar servidores en la nube (AWS/GCP), generando costos no presupuestados para el patrocinador.
Plan de contingencia: Aplicar técnicas estrictas de optimización de memoria en Python: downcasting de tipos de datos (ej. convertir float64 a float32 o int8), eliminación de variables temporales (del df) y recolección de basura forzada (gc.collect()) para mantener el costo operativo en cero.

8.3 RIESGOS DE DATOS

Riesgo: La escasa cobertura de datos descubierta en la fase inicial (hasta un 70% de valores nulos en métricas de vivienda y vehículos) podría degradar la capacidad de aprendizaje del algoritmo.
Plan de contingencia: En lugar de aplicar imputaciones artificiales (como rellenar con promedios que sesgarían la realidad), se utilizarán algoritmos basados en árboles de decisión avanzados (como LightGBM o XGBoost) que manejan la ausencia de datos de forma nativa. Además, se crearán variables binarias que capturen el valor implícito de la falta de información.

8.4 RIESGOS DE RESULTADOS

Riesgo: El modelo predictivo final logra un ROC-AUC inferior al umbral mínimo del 0.75, produciendo resultados menos dramáticos o efectivos que los esperados frente a las reglas manuales actuales.
Plan de contingencia: Pivotar la estrategia de un modelo de clasificación simple a un enfoque de ensamblaje (Ensemble Learning) o implementar algoritmos de aprendizaje no supervisado para segmentar a los clientes en clústeres de riesgo antes de predecir su probabilidad individual.

9. TERMINOLOGÍA

Para asegurar que los equipos de negocio (Dirección de Riesgos) y el equipo técnico de minería de datos "hablen el mismo idioma", se documentan los siguientes términos técnicos y de dominio. Esta lista se mantendrá actualizada en la documentación central del proyecto:

9.1 TERMINOLOGÍA DE NEGOCIO

Población No Bancarizada: Segmento de clientes que carece de un historial de crédito en el sistema financiero tradicional.
Underwriting: Proceso manual o heurístico mediante el cual los analistas del banco evalúan el riesgo de un cliente para aprobar o denegar un crédito.
EXT_SOURCE (1, 2 y 3): Calificaciones de riesgo normalizadas obtenidas de tres fuentes externas o burós de crédito diferentes.
TARGET: La variable objetivo del modelo. Representa el estado del crédito: 0 indica un préstamo pagado a tiempo, y 1 indica morosidad o impago.

9.2 TERMINOLOGÍA DE MINERÍA DE DATOS

Desbalance de Clases: Condición estadística del dataset donde una categoría domina sobre otra. En este proyecto, el 91.9% de la clase es 0 y solo el 8.1% es 1.
Feature Engineering (Ingeniería de Características): Proceso de crear nuevas variables predictivas (ej. "promedio de días de retraso") extrayendo y resumiendo la información matemática de los archivos secundarios.
ROC-AUC (Área bajo la curva ROC): Métrica principal de rendimiento técnico. Evalúa qué tan bien el modelo puede distinguir entre un cliente que pagará y uno que será moroso, independientemente del desbalance de las clases.
Data Leakage (Fuga de Datos): Error metodológico donde el modelo aprende de información que no estaría disponible en la vida real al momento de evaluar a un cliente nuevo.

10. OBJETIVOS DE MINERÍA DE DATOS

Tipo de problema de minería de datos: El proyecto aborda un problema de **Clasificación**, enfocado en extraer patrones multidimensionales ocultos que determinan el riesgo crediticio de los solicitantes dentro de un escenario de clases altamente desbalanceadas.

10.1 OBJETIVOS TÉCNICOS TEMPORALES

- Procesar eficientemente el 100% de los datos históricos ($\approx 2.6GB$) mediante técnicas de agregación y reducción (lectura por bloques, tipos reducidos) antes del hito de Preparación de Datos.
- Desarrollar el entrenamiento inicial, optimización y elección del umbral por costo del modelo con un límite de tiempo programado para el 17/11/2026 (Fin de la Fase 5).

> **Resultados deseados (Datos reales):** Utilizando el ecosistema de datos application_train.csv (que cuenta con $\approx 307,000$ solicitudes y una tasa de incumplimiento original del 8%), el modelo deberá segmentar los perfiles con precisión para reducir en al menos un 7% las pérdidas esperadas por impagos frente a la evaluación tradicional.

11. CRITERIOS DE RENDIMIENTO DE MINERÍA DE DATOS

- **Métodos de evaluación de modelos:** Debido al desbalance natural de las clases financieras, se descarta la simple precisión (accuracy) para evitar una falsa percepción de rendimiento al predecir la clase mayoritaria. La evaluación se realizará estrictamente utilizando ROC-AUC, PR-AUC, el estadístico KS, la Matriz de Confusión y el coeficiente MCC.
- **Puntos de referencia numéricos:** El criterio innegociable de éxito técnico es que los patrones descubiertos demuestren un valor predictivo real superando un **ROC-AUC** ≥ 0.75 en validación cruzada. Como medida de contingencia, si el ROC-AUC en el conjunto de validación es menor a 0.70 tras la Fase 5, el proyecto considerará activar un criterio de salida.

11.1 MEDICIONES SUBJETIVAS (EXPLICABILIDAD Y EQUIDAD)

- El modelo debe ser capaz de identificar estadísticamente el Top-5 de variables determinantes para cada perfil perfilado mediante la técnica algorítmica de explicabilidad SHAP.
- Para la auditoría de equidad, los patrones extraídos deben mantener una razón de tasas de aprobación entre grupos ≥ 0.8, descartando sesgos discriminatorios por variables sensibles o sus proxies.

> **Planificación del despliegue:** La implementación de los resultados (Fase 6 de CRISP-DM) está contemplada en el alcance del proyecto. Consiste en el desarrollo de un prototipo de inferencia automatizado donde el pipeline analítico será empaquetado en un servicio en Python con una capa REST, el cual será orquestado mediante contenedores para demostrar la viabilidad operativa sin requerir integración al core bancario.

12. PREGUNTAS CRÍTICAS

12.1 DESDE UNA PERSPECTIVA DE NEGOCIO

¿Qué espera obtener de este proyecto?
Se espera reducir las pérdidas operativas por morosidad en al menos un 7% y optimizar la eficiencia, logrando que el 75% de las solicitudes se evalúen automáticamente mediante reglas estadísticas, aislando únicamente la "zona gris" para revisión manual.

¿Cómo define la finalización de los trabajos?
La finalización está definida para el 08/12/2026 con la presentación final del proyecto, habiendo cumplido las 7 fases planificadas, incluyendo el despliegue funcional de un prototipo de inferencia (Fase 6 de CRISP-DM).

¿Dispone de la dotación presupuestaria y de los recursos necesarios para completar los objetivos?
Sí. Para la ejecución académica el costo real es $\approx S/0$ al usar herramientas open source y equipos propios. En el escenario del negocio simulado, se cuenta con un presupuesto total valorizado en S/ 189,200 para 5 años (que incluye infraestructura y contingencia).

¿Dispone de acceso a todos los datos necesarios para el proyecto?
Sí. Se cuenta con acceso local a las 7 tablas relacionales ($\approx 2.6GB$ de información histórica) que ya se encuentran seudonimizadas cumpliendo la Ley 29733 de Protección de Datos Personales.

¿Ha tratado con su equipo los riesgos y contingencias asociadas con el proyecto?
Sí, están formalmente documentados en el Project Charter. Se trataron 6 riesgos críticos, incluyendo la saturación de RAM, el desbalance de clases, la fuga de datos (leakage) y los sesgos discriminatorios, cada uno con su respectiva estrategia de mitigación.

¿Los resultados del análisis de costes/beneficios hacen que el proyecto sea viable?
Sí. El Business Case proyecta beneficios totales acumulados a 5 años por S/ 427,500 frente a un costo total de S/ 189,200, resultando en un Retorno de Inversión (ROI) de $\approx 126\%$, lo que hace al proyecto altamente viable.

12.2 DESDE UNA PERSPECTIVA DE MINERÍA DE DATOS

¿En qué forma puede ayudarle la minería de datos a cumplir sus objetivos de negocio?
Permitirá descubrir patrones multidimensionales ocultos en el masivo historial relacional de los clientes, calculando una probabilidad de impago que las revisiones heurísticas tradicionales no pueden detectar de forma eficiente.

¿Sabe qué técnicas de minería de datos producen los mejores resultados?
Sí. Se aplicarán algoritmos de clasificación supervisada optimizados para manejar el extremo desbalance de clases del ecosistema financiero.

¿Cómo puede saber que sus resultados son precisos o efectivos? (¿Hemos definido una medición del rendimiento de la minería de datos?)
Sí. El rendimiento no se medirá con una simple precisión (accuracy), sino mediante métricas especializadas: ROC-AUC (con un umbral de éxito ≥ 0.75), PR-AUC, estadístico KS y la Matriz de Confusión. Además, se utilizará SHAP para asegurar la explicabilidad estadística de los resultados.

¿Cómo se desplegarán los resultados de modelado? ¿Ha considerado el despliegue en su plan de proyecto?
Sí, está contemplado en la Fase 6. Los patrones extraídos se empaquetarán en un servicio de inferencia en Python expuesto mediante una capa REST y orquestado en contenedores (Docker) para demostrar la viabilidad operativa sin afectar el core bancario.

¿El plan de proyecto incluye todas las fases de CRISP-DM?
Sí, el cronograma en el Project Charter incluye explícitamente desde la Fase 1 (Comprensión del Negocio y Datos) hasta la Fase 6 (Implementación Analítica).

¿Los riesgos y dependencias se incluyen en el plan?
Sí. El plan aborda explícitamente las dependencias de recursos (cuellos de botella computacionales) y los riesgos analíticos derivados de imputar datos antes de tiempo o de no seleccionar correctamente las características limitadas por la memoria RAM.