

FASE 2: COMPRENSIÓN DE DATOS (CRISP-DM) Dataset: Home Credit Default Risk (Kaggle)

Grupo 12 — Equipo Fase 2 (Comprensión de Datos). Alcance exclusivo de este equipo: recopilación, descripción, exploración (EDA) y verificación de calidad. La preparación, modelado, evaluación y despliegue corresponden a otros grupos.

Integrante	Rol Fase 2
De la Cruz Aguilar, Gabriel Sonny	EDA application_train + calidad
Arevalo Mauricio, Diego Martin	Recopilación + integridad referencial
Chicata Serrato, Sebastian Joaquin	Descripción + EDA secundarias
Piñarreta Rojas, David Sebastian	Figuras + informe recopilación
Bayona Vera, Ashley Elizabeth	Legal/ética + calidad 8 dimensiones
Docente: Pedro Martín Lezama Gonzales	Fecha: octubre 2026

Fuentes: DATASET/ local (7 CSV + HomeCredit_columns_description.csv, ~2.66 GB); Sesiones/4 (Comprensión de los datos.pdf, Sesión 4.pdf); Rúbrica examen parcial §2.1–2.4. Cálculos verificados por código (pandas 3.0.5, scipy 1.18.1, conteo exacto por chunks). application_test.csv excluido por Charter.

1. Recopilación de datos iniciales (Rúbrica 2.1)

Orígenes. (i) Datos existentes transaccionales: 100% del insumo (histórico Home Credit + burós). (ii) Datos adquiridos: scores EXT_SOURCE_1/2/3 ya importados, sin compra adicional. (iii) Datos adicionales (encuestas): no requeridos ni autorizados.

Fuentes. Flat Files CSV con delimitador coma, una fila de encabezado y tipos mixtos; sin base de datos viva, warehouse, lake, API ni scraping. Diccionario oficial de 219 filas como SME documentado.

Archivo	Filas	Cols	Llave / grano
application_train.csv	307.511	122	SK_ID_CURR única; 1 fila = 1 solicitud (TARGET 8.07% mora)
bureau.csv	1.716.428	17	SK_ID_CURR+SK_ID_BUREAU; ~5.61 créditos por cliente
bureau_balance.csv	27.299.925	3	SK_ID_BUREAU; 1 fila = 1 mes (rango -96 a 0)
previous_application.csv	1.670.214	37	SK_ID_CURR+SK_ID_PREV; ~4.93 previas por cliente
POS_CASH_balance.csv	10.001.358	8	SK_ID_CURR+SK_ID_PREV; ~29.7 meses por cliente
installments_payments.csv	13.605.401	8	SK_ID_CURR+SK_ID_PREV; ~40.1 pagos por cliente
credit_card_balance.csv	3.840.312	23	SK_ID_CURR+SK_ID_PREV; ~37.1 meses, solo 33.7% clientes

Archivo	Filas	Cols	Llave / grano
HomeCredit_columns_description.csv	219	5	122 app + 38 prev (dicc.) + 23 cc + 17 bureau + 8 POS + 8 inst + 3 bal.

Hallazgo de formato: el diccionario declara 38 variables para previous_application pero el CSV real trae 37 columnas. Total en disco $\approx$ 2.66 GB. Riesgo de fusión: dos niveles (balance→buró→solicitud) y tres tablas vía SK_ID_PREV; en Fase 3 todo debe agregarse a nivel SK_ID_CURR.




Fig. 1. Cobertura de clientes por tabla (credit_card es subpoblación).




Fig. 2. Desbalance TARGET: 282.686 pagos (91.93%) vs 24.825 moras (8.07%). Accuracy inválido; usar ROC-AUC/PR-AUC.

2. Descripción de los datos + SME + legal/ética (Rúbrica 2.2)

2.1 Cantidad, tipos y codificación

application_train (307.511×122): 65 float64, 41 int64, 16 str (a category en Fase 3). Financieras: ingreso mediana S/ 147.150 (max 117.000.000, outlier); crédito mediana 513.531; anualidad mediana 24.903 (12 nulos); goods price mediana 450.000 (278 nulos). Scores EXT_SOURCE_1 (56.38% nulos) / _2 (0.21%) / _3 (19.83%), rango [0,1]. Temporales relativos negativos: DAYS_BIRTH media -16.037 días ($\approx$ 43.9 años), DAYS_EMPLOYED con centinela 365243 (18.01%), DAYS_REGISTRATION, DAYS_ID_PUBLISH. Categóricas: CONTRACT_TYPE (Cash 278.232 / Revolving 29.279),

CODE_GENDER (F 202.448 / M 105.059 / XNA 4), FLAG_OWN_CAR/REALTY (Y/N), INCOME_TYPE (8), EDUCATION (5), FAMILY (6), HOUSING (6), OCCUPATION (18 + 31.35% nulos), ORGANIZATION (58), WEEKDAY (7), flags binarios. Vivienda AVG/MODE/MEDI: 48–70% nulos; OWN_CAR_AGE 65.99% nulos.

Secundarias: bureau sin nulos en llaves; CREDIT_ACTIVE Closed 1.079.273 / Active 630.607 / Sold 6.527; CREDIT_TYPE Consumer 1.251.615 / Card 402.195; DPD media 0.82 días. bureau_balance sin nulos; STATUS C 13.6M / O 7.5M / X 5.8M / 1–5 ≈ 340k meses en mora. previous: Approved 62.1% / Canceled 18.9% / Refused 17.4%; RATE_INTEREST_* 99.64% nulos; bloque DAYS_* 40.3% nulos. POS: Active 9.15M; DPD media 11.6 días. installments: 8.43% cuotas con atraso, 9.37% pagos menores. credit_card: Active 3.70M; utilización mediana 1.1% (media 37.5%, cola sobreendeudada); PAYMENT_CURRENT 20% nulos con patrón monótono mensual.

2.2 Consideraciones legales, regulatorias y éticas (checklist SME)

Aspecto	Veredicto
Privacidad	Solo seudónimos SK_ID_*; sin nombres/DNI/contactos. Cumple Ley 29733 y estándar Kaggle/GDPR.
Seguridad	Dato estático local; prohibida la re-identificación y el cruce externo.
Precisión TARGET	Regla Home Credit (atraso >X días en 1 de primeras Y cuotas); se acepta como verdad terreno.
Sesgo	Género M 10.14% vs F 7.00% (paridad 0.69 < 0.8); educación 10.93%→1.83%; alquilados 12.31% vs casa 7.80%. Sensibles solo descriptivas; auditoría ≥0.8 en Fase 5 (otro grupo).
Gobernanza	Uso académico hasta 08/12/2026; sin producción por este equipo.

3. Exploración de datos — EDA (Rúbrica 2.3)

3.1 Univariado continuo

Distribuciones asimétricas a la derecha en montos; ratios crédito/ingreso (pago 3.27 vs mora 3.25) no separan clases por sí solos. DPD de cuotas centrado en –6 días (puntualidad). Utilización de tarjeta con minoría sobre el límite (max 11.8×).




Fig. 3. Correlación Pearson vs TARGET: EXT_SOURCE_3 –0.179, _2 –0.160, _1 –0.155; resto |r| < 0.08.




Fig. 4. EXT_SOURCE_3 por clase (scores menores en morosos).




Fig. 5. Edad: morosos ~3.4 años más jóvenes (densidad 25–40).

3.2 Categóricos vs TARGET (chi-cuadrado, $p < 0.05$ = dependiente)

Variable	Peor → mejor (tasa mora)	p chi2
CONTRACT_TYPE	Cash 8.35% → Revolving 5.48%	1.0e-65
CODE_GENDER	M 10.14% → F 7.00%	1.1e-200
FLAG_OWN_CAR	N 8.50% → Y 7.24%	9.3e-34
INCOME_TYPE	Unemployed 36.4%, Maternity 40% → Pensioner 5.39%	1.9e-266
EDUCATION	Lower 10.93% → Academic 1.83%	2.4e-219
FAMILY	Civil 9.94%, Single 9.81% → Widow 5.82%	7.7e-107
HOUSING	Rented 12.31%, With parents 11.70% → Office 6.57%	1.1e-88
OCCUPATION	Low-skill 17.15%, Drivers 11.33% → Accountants 4.83%	~0
ORGANIZATION	Transport:3 15.75% → Trade:4 3.12%	5.2e-299
WEEKDAY / EMAIL / CONT_MOBILE	Sin señal (p = 0.017 / 0.34 / 0.90)	No predictivas




Fig. 6. Mora por género (XNA n=4 no concluyente).




Fig. 7. Gradiente educativo perfecto.




Fig. 8. Vivienda: inquilinos y jóvenes con padres en riesgo.




Fig. 9. Ocupación: trabajo poco calificado concentra mora.

3.3 Ordinales (Spearman)

REGION_RATING_CLIENT 1→4.82% / 2→7.89% / 3→11.10% y su variante con ciudad 1→4.84% / 2→7.92% / 3→11.40% (monótonas, confirman score regional). HOUR nocturna (0–7h) 8–15% vs tarde 6.5–7.6% (proxy de canal). CNT_CHILDREN 0→7.71% hasta 4→12.82%. Spearman confirma Pearson (EXT_SOURCE_3 -0.166, DAYS_BIRTH +0.078).

3.4 Multivariado y dimensional

Multicolinealidad: CREDIT↔ANNUITY↔GOODS_PRICE >0.7 (a tratar en modelado). EXT_SOURCE_* mutuamente moderadas (complementarias). Hipótesis H1–H6: (1) menor EXT_SOURCE → mayor mora; (2) perfil joven+alquiler+baja educación+obrero/chofer; (3) DPD histórico supera a montos estáticos; (4) centinela empleo = jubilado/estudiante (mora 5.4% vs 8.7%); (5) subpoblaciones: sin buró 0.55%, con tarjeta 33.7%, zona gris EXT medio + 25–40 años; (6) objetivos de minería intactos (clasificación desbalanceada, ROC-AUC ≥0.75).




Fig. 10. bureau: 62.9% créditos cerrados, 36.7% activos.




Fig. 11. bureau_balance: 27.3M meses; mora 1–5 ≈ 340k.




Fig. 12. previous: 62.1% aprobadas, 17.4% rechazadas (cantera de inclusión segura).




Fig. 13. DPD de cuotas (línea 0 = a tiempo).

4. Verificación de calidad — 8 dimensiones (Rúbrica 2.4)




Fig. 14. Completitud: top nulos en principal (vivienda y EXT_SOURCE_1 dominan).

Dimensión	Diagnóstico	Plan para Preparación (otro grupo)
Exactitud	Outliers 117M ingreso, DPD 4.231 días; centinela 365243 (18.01%)	Topeo documentado; FLAG_NO_EMPLEADO; sin eliminar
Completitud	67/122 app con nulos; buró ANNUITY 71.47%; RATE_INTEREST 99.64%	Flags FALTA_X + NaN nativo; excluir RATE_INTEREST
Consistencia	Dicc. 38 vs real 37 en previous; resto consistente	Registrar inconsistencia; validación de formato
Integridad	buró 99.45% train; tarjeta 33.68%; previas/POS/cuotas incluyen test	Filtrar por SK_ID_CURR train; 0 huérfanos tras filtro
Razonabilidad	Segmentos coherentes; XNA-org 55.374 = centinela	Auditar Unemployed n=22 e ingreso 117M caso a caso
Oportunidad	Estático 2018, historia -96 meses, media -30.7	Válido académico; no productivo sin refresco
Unicidad	0 duplicados app; llaves únicas train/bureau/previous	Test unicidad SK_ID_BUREAU/PREV en Fase 3
Validez	Dominios OK; XNA género n=4; CNT_CHILD max 19	str→category; NUM_INSTALLMENT_VERSION float por nulos

5. Conclusiones y entrega a Fase 3

1) Datos suficientes y aptos: 307.511 solicitudes con 8.07% de mora y ~55.4M registros relacionales permiten modelar. 2) Señal confirmada: scores externos, edad y DPD histórico; montos solos no discriminan. 3) Calidad conocida y acotada: ausencia informativa (no aleatoria) en vivienda/scores/tarjeta; un outlier extremo; una inconsistencia de diccionario. 4) Riesgos transferidos: desbalance (no usar accuracy), subpoblación tarjeta, sesgo género/educación, leakage en agregación. El grupo de Preparación recibe: inventario exacto, flags propuestos (FALTA_X, FLAG_NO_EMPLEADO, TIENE_TARJETA), lista de exclusión (RATE_INTEREST_*, FLAG_MOBIL) y checklist anti-leakage (split antes de agregar).

Referencias (IEEE)

[1] Home Credit Group, "Home Credit Default Risk," Kaggle Competition, 2018. [Online]. Available: <https://www.kaggle.com/competitions/home-credit-default-risk/overview>. [2] P. Chapman et al., "CRISP-DM 1.0: Step-by-step data mining guide," SPSS, 2000. [3] R. Agrawal et al., "KDD process model," en Advances in Knowledge Discovery and Data Mining, AAAI, 1996. [4] Congreso de la República del Perú, "Ley N.º 29733, Ley de Protección de Datos Personales," El Peruano, 2011. [5] W. H. McKinney, "Data structures for statistical computing in Python," Proc. SciPy, 2010, pp. 56–61. [6] C. R. Harris et al.,

“Array programming with NumPy,” *Nature*, vol. 585, pp. 357–362, 2020. [7] P. Virtanen et al., “SciPy 1.0,” *Nature Methods*, vol. 17, pp. 261–272, 2020. [8] J. D. Hunter, “Matplotlib: A 2D graphics environment,” *Comput. Sci. Eng.*, vol. 9, no. 3, pp. 90–95, 2007.

Anexos

Anexo A (tablas): top-15 nulos por tabla con % exacto; frecuencias completas de STATUS/CREDIT_TYPE/CONTRACT_STATUS; correlaciones Pearson y Spearman; tasas por ocupación/organización (58 categorías). Anexo B (figuras F01–F15 en alta resolución, carpeta figuras/). Anexo C (reproducibilidad): scripts en C:\Users\diego\AppData\Local\Temp\opencode\ (perfil_fase2.py, eda_fase2.py, gen_figs.py) y conteos verificados el 11/10/2026. Anexo D (diccionario): HomeCredit_columns_description.csv, 219 filas.