UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS

Fundada en 1551

FACULTAD DE INGENIERÍA DE SISTEMAS E INFORMÁTICA
ESCUELA PROFESIONAL DE INGENIERÍA DE SOFTWARE - LIMA



Preparación de datos

Grupo 12

Integrantes:

De la Cruz Aguilar Gabriel Sonny

Arevalo Mauricio Diego Martin

Chicata Serrato Sebastian Joaquin

Piñarreta Rojas David Sebastian

Bayona Vera Ashley Elizabeth

Docente:
Pedro Martín Lezama Gonzales

Asignatura:
Minería de Datos

1. Introducción y alcance

La Fase 3 deja application_train y las tablas relacionales listas para modelar, **sin imputar los faltantes y sin eliminar valores extremos**: los faltantes se conservan como información (con banderas de ausencia) y los extremos se acotan con una marca que permite recuperar el valor original. El trabajo se hace sobre el dataset Home Credit Default Risk [1], seudonimizado conforme a la Ley 29733 [3], dentro de la metodología CRISP-DM [2]. La decisión de no imputar sigue la estrategia fijada en la Comprensión del Negocio (riesgo de datos 8.3) y el plan de preparación entregado por la Fase 2 [4].

El informe cubre los dos apartados de la rúbrica para la Preparación de los Datos [2]: **3.1 Selección de los datos** (qué tablas, filas y columnas entran o salen) y **3.2 Limpieza de los datos** (faltantes, patrón de faltantes, atípicos, duplicados, errores e inconsistencias, incompletos). Las cifras base provienen de la Fase 2; las que dependen de la ejecución del cuaderno fase3_preparacion.ipynb aparecen como ‹completar: archivo›, con el nombre de la tabla CSV que las contiene en salida_fase3.zip.

Fuera de alcance de este informe: la consolidación de las seis tablas por SK_ID_CURR, las variables derivadas, la selección por importancia y el split train/validación (tareas posteriores de la Fase 3 del Charter), y el modelado.

Insumos recibidos de la Fase 2

Insumo	Valor
Base de trabajo	application_train: 307.511 solicitudes × 122 columnas; TARGET con 8.07% de mora (24.825 casos)
Tablas relacionales	bureau (1.716.428), bureau_balance (27.299.925), previous_application (1.670.214), POS_CASH_balance (10.001.358), installments_payments (13.605.401), credit_card_balance (3.840.312)
Exclusión por Charter	application_test.csv no se usa
Hallazgos de calidad a tratar	centinela 365243 en DAYS_EMPLOYED (18.01%); ingreso máximo de 117.000.000; XNA en género (n=4) y organización (55.374); 67 de 122 columnas con nulos; RATE_INTEREST_* con

Insumo	Valor
	99.64% de nulos; diccionario con 38 columnas contra 37 reales en previous_application
Entrega recibida	banderas propuestas (FALTA_X, FLAG_NO_EMPLEADO, TIENE_TARJETA), lista de exclusión (RATE_INTEREST_*, FLAG_MOBIL) y checklist anti-leakage (split antes de agregar)

2. Selección de los datos (rúbrica 3.1)

Se conservan las siete tablas de modelado, ninguna fila de application_train se descarta y solo salen del conjunto application_test, las filas de clientes ajenos a train y las columnas casi constantes o casi vacías.

2.1 Tablas incluidas y excluidas

Tabla	Decisión	Motivo
application_train	Incluir (base)	1 fila = 1 solicitud; contiene TARGET y SK_ID_CURR único
application_test	Excluir	Sin TARGET y fuera del alcance fijado por el Charter
bureau, bureau_balance	Incluir	Historial en burós; bureau_balance se enlaza vía SK_ID_BUREAU; cobertura de 99.4% de los clientes train [4]
previous_application, POS_CASH_balance, installments_payments	Incluir	Cobertura cercana al 100% de los clientes train [4]; origen de las señales de comportamiento de pago
credit_card_balance	Incluir con bandera TIENE_TARJETA	Solo 33.7% de los clientes tiene tarjeta: la ausencia de registros es una subpoblación, no un error

Tabla	Decisión	Motivo
HomeCredit_columns_description.csv	Solo referencia	Diccionario de 219 filas; se usa para validar columnas, no entra al modelo

2.2 Filas incluidas y excluidas

- **application_train: se conservan las 307.511 filas.** No hay duplicados [4] y los valores extremos se acotan, no se eliminan, para no perder casos de mora (8.07% de la base).
- **Tablas secundarias: se filtran a los SK_ID_CURR de train.** previous_application, POS_CASH_balance e installments_payments traen también clientes de test [4]; conservarlos mezclaría información ajena a la muestra. bureau_balance se filtra por los SK_ID_BUREAU de los burós ya filtrados. Filas conservadas y descartadas por tabla: ‹completar: seleccion_tablas.csv›.
- **Casos atípicos de etiqueta o categoría** (CODE_GENDER = XNA, n=4) no se eliminan: pasan a valor faltante en 3.2.

2.3 Columnas incluidas y excluidas

El cuaderno aplica dos criterios objetivos, parametrizables en la celda 3:

Criterio	Alcance	Umbral
Casi constante: el valor dominante no aporta variación	application_train	≥ 99.9% de las filas con el mismo valor
Casi vacía: sin información suficiente para aprender	tablas secundarias	≥ 95% de nulos

Con estos criterios se excluyen RATE_INTEREST_PRIMARY y RATE_INTEREST_PRIVILEGED de previous_application (99.64% de nulos) y FLAG_MOBIL, propuesta de la Fase 2 que el cuaderno confirma solo si supera el umbral. La lista completa, con motivo por columna, queda en ‹completar: seleccion_columnas_excluidas.csv›.

Se **conservan** aunque tengan muchos nulos las columnas de vivienda (48–70%), OWN_CAR_AGE (65.99%) y EXT_SOURCE_1 (56.38%) porque quedan por debajo del umbral y su ausencia es informativa (3.2.2). AMT_CREDIT, AMT_ANNUITY y AMT_GOODS_PRICE (correlación > 0.7 entre sí [4]) también se conservan: los árboles de decisión toleran la colinealidad y su depuración corresponde a la selección de variables posterior.

Decisión abierta: CODE_GENDER, NAME_EDUCATION_TYPE y NAME_FAMILY_STATUS se mantienen en el conjunto para poder auditar sesgos en la Fase 5, pero la Comprensión del Negocio exige no usar variables protegidas como predictoras. El equipo debe decidir si salen de la lista final de variables.

3. Limpieza de los datos (rúbrica 3.2)

La limpieza v1 aplica seis tratamientos a application_train; cada uno queda registrado con su regla y las filas afectadas en ‹completar: registro_limpieza.csv›. Ninguno elimina observaciones.

3.1 Valores faltantes

67 de las 122 columnas de application_train tienen nulos [4]. Los más altos se concentran en vivienda, en el vehículo y en los puntajes externos:

Tabla	Columna o bloque	% de nulos
application_train	Vivienda (*_AVG, *_MODE, *_MEDI)	48–70
application_train	OWN_CAR_AGE	65.99
application_train	EXT_SOURCE_1	56.38
application_train	OCCUPATION_TYPE	31.35
application_train	EXT_SOURCE_3	19.83
bureau	AMT_ANNUITY	71.47
previous_application	Bloque DAYS_*	40.3
credit_card_balance	PAYMENT_CURRENT	20

Decisión: no imputar. Un valor medio o mediano inventaría un dato que nunca existió y borraría la señal de que falta: quien no declara datos de vivienda o no tiene tarjeta es un tipo de cliente, no un error de captura. LightGBM y XGBoost manejan los faltantes de forma nativa [5], [6]. En su lugar:

- Los nulos se dejan como NaN.
- Se crea una **bandera FALTA_* por cada bloque de columnas con el mismo patrón de ausencia**, solo si la columna tiene al menos 5% de nulos. Evita decenas de indicadores

redundantes (por ejemplo, uno solo para todo el bloque de vivienda). Banderas creadas: ‹completar: banderas_ausencia_creadas.csv›.

- La regresión logística de referencia de la Fase 4 sí exige valores completos: allí se imputará dentro del pipeline, ajustando la regla solo con train.

3.2 Patrón de datos faltantes

Para decidir si la ausencia es aleatoria o informativa [7], el cuaderno aplica cuatro análisis:

1. **Bloques de patrón idéntico:** agrupa las columnas que faltan exactamente en las mismas filas (‹completar: faltantes_bloques_patron_identico.csv›).
2. **Correlación entre indicadores de ausencia** de las 20 columnas con más nulos: valores cercanos a 1 confirman que faltan juntas (Fig. 2).
3. **Ausencia contra TARGET:** compara la tasa de mora cuando el valor falta y cuando existe, con prueba chi-cuadrado en las columnas con ≥ 1% de nulos (Fig. 3, ‹completar: faltantes_vs_target.csv›).
4. **Nulos por fila:** distribución de la cantidad de campos vacíos por solicitud y su tasa de mora (Fig. 4, ‹completar: faltantes_por_fila.csv›).

La Fase 2 ya anticipó que la ausencia en vivienda, puntajes externos y tarjeta **no es aleatoria** [4]. Si en una columna el chi-cuadrado da $p < 0.05$ y la diferencia de mora es relevante, se descarta que falte completamente al azar [7] y la bandera FALTA_* se justifica como variable predictora. Conclusión por bloque: ‹completar con los resultados de faltantes_vs_target.csv›.

Fig. 1. Top 20 de columnas con más nulos en application_train. ‹insertar F_nulos_top20.png›

Fig. 2. Correlación entre indicadores de ausencia. ‹insertar F_patron_faltantes_corr.png›

Fig. 3. Tasa de mora con el valor ausente y presente (15 columnas de mayor diferencia). ‹insertar F_faltante_vs_target.png›

Fig. 4. Nulos por solicitud. ‹insertar F_nulos_por_fila.png›

3.3 Valores atípicos

Cada variable numérica se revisa con la regla del rango intercuartílico (IQR) de Tukey [8], con cercas a 1.5× y a 3× (esta última marca los extremos severos), junto con los percentiles 1, 99 y 99.9. Se analizan 12 columnas de application_train y 1 a 5 columnas numéricas por cada tabla secundaria (Fig. 5; ‹completar: atipicos_application_train.csv y atipicos_secundarias.csv›).

La Fase 2 identificó los casos más graves: un ingreso máximo de 117.000.000 frente a una mediana de 147.150 y retrasos (DPD) de hasta 4.231 días [4]. El tratamiento distingue tres situaciones:

Situación	Variables	Tratamiento	Justificación
Centinela, no atípico	DAYS_EMPLOYED = 365243 (18.01% de las solicitudes)	Pasa a NaN y se crea FLAG_NO_EMPLEADO	365243 días son unos 1.000 años: es un código de "sin empleo", no una medición. La Fase 2 mostró mora de 5.4% en este grupo frente a 8.7% en el resto [4]
Cola extrema implausible	AMT_INCOME_TOTAL, OBS_30_CNT_SOCIAL_CIRCLE, OBS_60_CNT_SOCIAL_CIRCLE, AMT_REQ_CREDIT_BUREAU_QRT	Topeo al percentil 99.9 y bandera TOPEADO_<variable>	Conserva la fila y el orden del valor, y la bandera permite recuperar qué casos eran extremos. Efecto en media y desviación: ‹completar: topeo_antes_despues.csv› (Fig. 7)
Asimetría plausible	AMT_CREDIT, AMT_ANNUITY, AMT_GOODS_PRICE, DAYS_BIRTH, CNT_CHILDREN, CNT_FAM_MEMBERS, OWN_CAR_AGE	Sin cambios en esta versión	Montos y edades altos son posibles y los modelos de árboles no se ven afectados por la escala

Los extremos de las tablas secundarias se documentan pero no se modifican aquí: se tratan al agregarlas por cliente, donde máximos y promedios los absorben. Los topes de percentil de este informe se calculan sobre todo application_train solo para documentar; en el pipeline final deben **recalcularse únicamente con train después del split** para evitar fuga de datos [9].

Fig. 5. Porcentaje de valores fuera de 3× IQR por variable. ‹insertar F_atipicos_pct.png›

Fig. 6. DAYS_EMPLOYED sin el centinela, en años de empleo. ‹insertar F_days_employed.png›

Fig. 7. Ingreso antes y después del topeo al percentil 99.9. ‹insertar F_ingreso_antes_despues.png›

3.4 Datos duplicados

application_train no tiene filas duplicadas ni SK_ID_CURR repetidos [4]; el cuaderno lo reverifica (‹completar: duplicados_application_train.csv›). En las tablas secundarias aplica dos pruebas, ambas por bloques mediante hash de pandas [10] para no cargar las tablas completas:

Tabla	Llave natural evaluada
bureau	SK_ID_BUREAU
bureau_balance	SK_ID_BUREAU + MONTHS_BALANCE
previous_application	SK_ID_PREV
POS_CASH_balance, credit_card_balance	SK_ID_PREV + MONTHS_BALANCE
installments_payments	SK_ID_PREV + NUM_INSTALMENT_VERSION + NUM_INSTALMENT_NUMBER

La Fase 2 ya confirmó llaves únicas en bureau y previous_application [4]. Resultados para el resto: ‹completar: duplicados_secundarias.csv›. **Regla de decisión:** solo se eliminan las filas idénticas en todas sus columnas; una repetición de llave con valores distintos se revisa antes de actuar, porque en installments_payments puede ser un pago fraccionado de una misma cuota.

3.5 Errores e inconsistencias

El cuaderno ejecuta 20 reglas de coherencia, más una revisión de texto en las categóricas, sobre application_train y cuenta las filas que las incumplen (‹completar: inconsistencias_application_train.csv›). Se agrupan así:

Regla	Filas afectadas	Tratamiento
CODE_GENDER = XNA	4 [4]	Pasa a NaN
ORGANIZATION_TYPE = XNA	55.374 [4]	Pasa a NaN; coincide con el centinela de empleo (jubilados y

Regla	Filas afectadas	Tratamiento
		similares)
DAYS_EMPLOYED = 365243	18.01% [4]	Ver 3.3
Edad < 18 o > 100 años; DAYS_BIRTH ≥ 0	‹completar›	Marcar y auditar
DAYS_EMPLOYED positivo distinto del centinela; años empleado > edad; inicio laboral antes de los 14 años	‹completar›	Marcar y auditar
CNT_FAM_MEMBERS < CNT_CHILDREN	‹completar›	Marcar y auditar
AMT_INCOME_TOTAL ≤ 0; AMT_CREDIT ≤ 0; AMT_ANNUITY > AMT_CREDIT	‹completar›	Marcar y auditar
FLAG_OWN_CAR contradice OWN_CAR_AGE (N con edad informada; Y con edad vacía)	‹completar›	Marcar y auditar
EXT_SOURCE_1/2/3 fuera de [0, 1]	‹completar› (la Fase 2 reportó rango [0, 1])	Marcar y auditar
DAYS_REGISTRATION o DAYS_ID_PUBLISH > 0	‹completar›	Marcar y auditar
Espacios sobrantes o variantes de mayúsculas en categóricas	‹completar›	Normalizar texto

Solo los códigos XNA y el centinela se corrigen automáticamente porque su significado es conocido. Los demás casos se marcan y se auditan uno a uno antes de corregirlos, como acordó la Fase 2 con el ingreso de 117.000.000 y los 22 solicitantes Unemployed [4]. En el diccionario de datos, previous_application declara 38 variables y el archivo trae 37 [4]; el cuaderno contrasta cada tabla contra el diccionario (‹completar: diccionario_vs_csv.csv›) y la diferencia se registra sin alterar los datos.

3.6 Datos incompletos y tipos de dato

Incompletitud por ausencia de registros. No todos los clientes aparecen en todas las tablas: el 0.55% no tiene buró y solo el 33.7% tiene tarjeta [4]. Esa falta no se rellena: se resuelve en la consolidación con indicadores de presencia (`TIENE_TARJETA` y su equivalente para buró), de modo que "sin historial" sea una categoría y no un cero engañoso.

Tipos y memoria. Las 16 columnas de texto pasan a `category` y las numéricas se reducen al menor tipo posible (`float32`, `int8`), requisito para sostener el procesamiento en un equipo local de 16 GB (riesgo financiero 8.2). Memoria antes y después: ‹completar: `antes_despues_application_train.csv`›.

3.7 Resumen de tratamientos aplicados

Problema	Tratamiento	Filas afectadas	Reversible
Columnas casi constantes o con ≥ 95% de nulos	Exclusión	‹completar: columnas›	Sí, el archivo original no se altera
Centinela 365243 en `DAYS_EMPLOYED`	`NaN` + `FLAG_NO_EMPLEADO`	18.01%	Sí, la bandera conserva la marca
`XNA` en `CODE_GENDER`	`NaN`	4	Sí
XNA en `ORGANIZATION_TYPE`	`NaN`	55.374	Sí
Extremos en 4 variables	Topeo p99.9 + `TOPEADO_*`	‹completar: `topeo_antes_despues.csv`›	Sí, por la bandera
Columnas con ≥ 5% de nulos	Banderas `FALTA_*` por bloque	‹completar: nº de banderas›	No aplica
Texto y tipos numéricos	`category` y reducción de tipos	307.511	Sí

4. Resultado y entrega a las siguientes tareas

La limpieza v1 produce `application_train_clean.parquet`: las 307.511 solicitudes originales, sin imputaciones, con los centinelas y códigos `XNA` convertidos a faltante, cuatro variables acotadas y tres

familias de banderas que preservan lo que se modificó (FLAG_NO_EMPLEADO, TOPEADO_*, FALTA_*). Dimensiones, nulos y memoria antes y después: ‹completar: antes_despues_application_train.csv›.

4.1 Reglas para no contaminar la validación

La fuga de datos es el riesgo que más puede inflar el ROC-AUC sin que se note [9]. Para cumplir el checklist anti-leakage de la Fase 2 [4]:

1. Los topes de percentil y cualquier imputación se **calculan solo con train, después del split**, y se aplican a validación con esos mismos valores.
2. Las agregaciones de las tablas secundarias se hacen sobre los clientes de train ya filtrados (2.2), nunca con información de application_test.
3. Las banderas FALTA_*, FLAG_NO_EMPLEADO y TOPEADO_* se derivan de cada fila por separado y no usan TARGET, por lo que no filtran la etiqueta.

4.2 Próximos pasos según el cronograma

Tarea (Fase 3 del Charter)	Responsable	Fechas
Selección de variables (importancia, correlación, casi constantes)	De la Cruz	11 al 14 oct 2026
Split train/validación estratificado	De la Cruz	13 al 15 oct 2026
Documentar variables sensibles y proxies (anexo de auditoría)	Bayona	14 al 17 oct 2026
Almacenamiento optimizado en Parquet	Arevalo	15 al 20 oct 2026

4.3 Pendientes antes de entregar

- Ejecutar el cuaderno con SOLO_APPLICATION = False y completar todas las marcas ‹completar› con las tablas de salida_fase3.zip.
- Insertar las siete figuras de figuras/ y numerarlas como en este informe.
- Decidir si las variables protegidas (2.3) salen de la lista final de predictores.
- Redactar las conclusiones por bloque de la sección 3.2 con los resultados de faltantes_vs_target.csv.

Referencias (IEEE)

[1] Home Credit Group, “Home Credit Default Risk,” Kaggle Competition, 2018. [Online]. Available: https://www.kaggle.com/competitions/home-credit-default-risk/overview

[2] P. Chapman et al., “CRISP-DM 1.0: Step-by-step data mining guide,” SPSS Inc., 2000.

[3] Congreso de la República del Perú, “Ley N.º 29733, Ley de Protección de Datos Personales,” El Peruano, 2011.

[4] Grupo 12, “Fase 2: Comprensión de los Datos (CRISP-DM),” Facultad de Ingeniería de Sistemas e Informática, Universidad Nacional Mayor de San Marcos, Lima, Perú, oct. 2026.

[5] G. Ke et al., “LightGBM: A highly efficient gradient boosting decision tree,” in Proc. Adv. Neural Inf. Process. Syst. (NIPS), 2017, pp. 3146–3154.

[6] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discovery Data Mining, 2016, pp. 785–794.

[7] R. J. A. Little and D. B. Rubin, *Statistical Analysis with Missing Data*, 3rd ed. Hoboken, NJ, USA: Wiley, 2019.

[8] J. W. Tukey, *Exploratory Data Analysis*. Reading, MA, USA: Addison-Wesley, 1977.

[9] S. Kaufman, S. Rosset, C. Perlich, and O. Stitelman, “Leakage in data mining: Formulation, detection, and avoidance,” *ACM Trans. Knowl. Discov. Data*, vol. 6, no. 4, pp. 1–21, 2012.

[10] W. McKinney, “Data structures for statistical computing in Python,” in *Proc. 9th Python in Science Conf.*, 2010, pp. 56–61.

Anexos

Anexo A. Tablas generadas por el cuaderno (carpeta `tablas/` de `salida_fase3.zip`)

Archivo	Contenido	Sección
`seleccion_tablas.csv`	Filas totales, en train y fuera de train por tabla	2.2
`seleccion_columnas_excluidas.csv`	Columnas excluidas con su motivo	2.3

Archivo	Contenido	Sección
nulos_application_train.csv, nulos_secundarias.csv	% de nulos por columna	3.1
faltantes_bloques_patron_identico.csv	Columnas que faltan en las mismas filas	3.2
faltantes_vs_target.csv, faltantes_por_fila.csv	Mora según presencia del dato y nulos por fila	3.2
atipicos_application_train.csv, atipicos_secundarias.csv	Percentiles y conteo fuera de 1.5× y 3× IQR	3.3
topeo_antes_despues.csv	Efecto del topeo al percentil 99.9	3.3
duplicados_application_train.csv, duplicados_secundarias.csv	Duplicados por fila completa y por llave	3.4
inconsistencias_application_train.csv, diccionario_vs_csv.csv	Reglas de coherencia y contraste con el diccionario	3.5
banderas_ausencia_creadas.csv, registro_limpieza.csv, antes_despues_application_train.csv	Banderas, bitácora de pasos y comparación antes/después	3.1, 3.6, 3.7, 4

Anexo B. Figuras (carpeta figuras/): F_nulos_top20.png, F_patron_faltantes_corr.png, F_faltante_vs_target.png, F_nulos_por_fila.png, F_atipicos_pct.png, F_days_employed.png, F_ingreso_antes_despues.png.

Anexo C. Reproducibilidad. Cuaderno fase3_preparacion.ipynb (pandas [10], matplotlib; SciPy opcional) que lee los CSV desde ../data/raw, procesa las tablas secundarias por bloques de 1.000.000 de filas y guarda resumen.json. Parámetros usados: UMBRAL_VACIO = 95, UMBRAL_CONSTANTE = 99.9, UMBRAL_BANDERA = 5.

Anexo D. Diccionario de datos: HomeCredit_columns_description.csv, 219 filas.