

UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS

Fundada en 1551

FACULTAD DE INGENIERÍA DE SISTEMAS E INFORMÁTICA
ESCUELA PROFESIONAL DE INGENIERÍA DE SOFTWARE - LIMA



Primer Avance

Grupo 12

Integrantes:

De la Cruz Aguilar Gabriel Sonny

Arevalo Mauricio Diego Martin

Chicata Serrato Sebastian Joaquin

Piñarreta Rojas David Sebastian

Bayona Vera Ashley Elizabeth

Docente:

Pedro Martín Lezama Gonzales

Asignatura:

Minería de Datos

PROJECT CHARTER

Título del Proyecto: Sistema Predictivo de Riesgo Crediticio

Patrocinador del Proyecto: Evaluación Académica

Fecha de Elaboración: 15/09/2026

Gerente del Proyecto: Sebastian Joaquin Chicata Serrato

Cliente del Proyecto: Pedro Martín Lezama Gonzales

Propósito del Proyecto

Desarrollar un modelo de aprendizaje automático capaz de predecir la probabilidad de que un cliente incumpla con un préstamo, utilizando su historial transaccional, con el fin de optimizar el proceso de aprobación de créditos y reducir las pérdidas por morosidad.

Descripción General del Proyecto:

El proyecto procesará múltiples tablas relacionales provenientes del dataset de Home Credit. Se aplicarán técnicas de ingeniería de datos para consolidar historiales de pagos, saldos de tarjetas y datos de burós externos en un único perfil por cliente. Posteriormente, se entrenarán modelos predictivos capaces de lidiar con clases desbalanceadas para emitir un puntaje de riesgo preciso. El dataset se compone de 7 tablas relacionales del dataset público de Home Credit (≈ 2.6 GB): la tabla principal `application_train` ($\approx 307,000$ solicitudes, con la variable objetivo `TARGET`) y seis tablas históricas que se agregan por `SK_ID_CURR` para construir un perfil único por cliente.

Límites del Proyecto:

- El proyecto se limitará al uso del archivo `application_train.csv` y sus tablas relacionales asociadas para las fases de entrenamiento y validación interna. No se utilizarán los archivos `application_test.csv` ni `sample_submission.csv` proporcionados para la competencia original de Kaggle.
- No consideramos una Interfaz web de usuario final, integración con el sistema real de originación y despliegue productivo.

Principales Entregables

1. Pipeline de limpieza de datos e ingeniería de características (código fuente).
2. Modelo predictivo entrenado y optimizado para lidiar con el desbalanceo de clases.
3. Reporte de validación técnica: ROC-AUC, PR-AUC, KS, matriz de confusión al umbral elegido por costo esperado y auditoría de sesgos.
4. API REST en TypeScript/Express que consume un servicio de inferencia en Python (FastAPI), orquestados con docker-compose.
5. Ficha del modelo (model card): variables usadas, explicabilidad y limitaciones.
6. Reporte de prueba de carga y seguridad (OWASP).

Requisitos de Alto nivel

1. El modelo debe procesar clientes con datos faltantes sin fallar.
2. Cada predicción debe incluir los principales factores que la explican (SHAP).
3. La API no debe recibir, almacenar ni registrar en logs datos de contacto o nombres.
4. La API debe responder con latencia $p95 < 500$ ms.
5. El modelo y la API deben ejecutarse en contenedores Docker (docker-compose).

6. Las solicitudes con score intermedio (zona gris) deben derivarse a revisión humana.	
Riesgo General del Proyecto	
1. Colapso de recursos computacionales (saturación de RAM) debido al volumen de datos crudos (≈ 2.6 GB). Mitigación: Leer cada tabla por bloques con tipos reducidos (float32/int32/category), agregar por cliente y guardar en Parquet antes de pasar a la siguiente. 2. Falsa precisión del modelo debido al desbalance marcado (prediciendo mayoritariamente la clase "no moroso"). Mitigación: Usar PR-AUC y recall (no accuracy), pesos de clase y validación estratificada. 3. Fuga de datos (leakage) al agregar tablas o imputar antes de separar train/validación, lo que infla el AUC. Mitigación: split previo y validación cruzada. 4. Sesgo discriminatorio por variables como género, edad o sus proxies. Mitigación: Auditoría de sesgos, evaluar excluir género y edad y revisar variables proxy. 5. Diferencia entre las features del entrenamiento y las disponibles en la API. Mitigación: Reutilizar el mismo código de agregación y el pipeline serializado en entrenamiento e inferencia. 6. Cronograma ajustado de 7 fases en 12 semanas. Mitigación: Priorizar un MVP (modelo + API mínima) y hacer revisiones semanales.	
Objetivos del Proyecto	Criterios del Éxito
Alcance:	
Consolidar las tablas relacionales en un único perfil por cliente	Integrar las 6 tablas relacionales (bureau, bureau_balance, previous_application, POS_CASH_balance, credit_card_balance, installments_payments), agregadas por SK_ID_CURR, en una única tabla de entrenamiento (~307,000 clientes)
Tiempo:	
Entrega final del proyecto	Entrega el 08/12/2026, con las 7 fases cumplidas en las fechas de los hitos
Costo:	
Costo computacional y de recursos	Costo real en efectivo $\approx$ S/ 0 (herramientas open source y equipos propios); pipeline completo ejecutable en un equipo local estándar. Presupuesto simulado del escenario empresarial: S/ 189,200 (ver Business Case)
Otro:	
Rendimiento predictivo	ROC-AUC ≥ 0.75 en validación interna; PR-AUC, KS y recall al umbral elegido reportados.
Resumen de Hitos	Fecha de Vencimiento
Fase 1: Comprensión del Negocio y Datos	22/09/2026
Fase 2: Preparación de Datos (Limpieza e imputación)	06/10/2026
Fase 3: Ingeniería de Características y Cruce de Tablas	20/10/2026
Fase 4: Modelado (Entrenamiento inicial)	03/11/2026
Fase 5: Evaluación y Optimización (incluye auditoría de sesgos y elección del umbral por costo)	17/11/2026
Fase 6: Despliegue local (API + Docker)	01/12/2026
Fase 7: Presentación Final	08/12/2026

Recursos financieros preaprobados:	
Sin presupuesto en efectivo (proyecto académico). Los costos del escenario empresarial se valorizan de forma simulada en el Business Case (referencia: S/ 189,200 a 5 años, incluye 10% de contingencia).	
Stakeholder	Rol
Gerente del Proyecto (S. Chicata)	Planificación, seguimiento y reporte
Cliente (P. Lezama)	Validación de requisitos y aceptación de entregables
Patrocinador (Evaluación Académica)	Aprobación del charter y evaluación final
Equipo de Ciencia de Datos (De la Cruz Aguilar)	Pipeline, modelado, validación y explicabilidad
Equipo Backend/DevOps (Piñarreta Rojas)	API Express, Docker y pruebas de carga
Riesgos y Cumplimiento (Bayona Vera)	Validar explicabilidad y ausencia de sesgo (SBS, Ley 29733)
Área de TI (Arevalo Mauricio)	Estándares de despliegue en contenedores
Analistas de crédito	Usuarios de la zona gris y retroalimentación
Criterios de salida	
- Cuando el retraso acumulado del cronograma supere 2 semanas sin un plan de recuperación aprobado por el patrocinador. - Cuando la estimación a la conclusión (EAC) supere 120% del presupuesto. - Si tras la Fase 5 el ROC-AUC de validación sigue < 0.70. - Si el dataset deja de estar disponible o cambia una norma que impida su uso.	
Autoridad del gerente del proyecto	
Decisiones de dotación del personal	
Asigna tareas dentro del equipo	
Gestión del cronograma	
aprueba retrasos de hasta 1 semana en un hito sin afectar la entrega final; retrasos mayores los decide el patrocinador.	
Decisiones técnicas	
Elige algoritmos y librerías con el equipo de Ciencia de Datos; cambios de arquitectura los consulta con el cliente	
Resolución de Conflictos	
nivel 1 el gerente, nivel 2 el cliente, nivel 3 el patrocinador	
Autoridad del patrocinador	
Control de cronograma y presupuesto, aprobación de cambios de alcance y aceptación final.	
Firmas	
Firma del Gerente del Proyecto	Firma del Patrocinador
Sebastian Joaquin Chicata Serrato	Pedro Martín Lezama Gonzales
Nombre del Gerente del Proyecto	Nombre del patrocinador
Fecha:	Fecha:

Business Case: Sistema Predictivo de Riesgo Crediticio (Home Credit)

Justificación del negocio, problema/Oportunidad y Propósito

El alto volumen de solicitudes de crédito y la dependencia de evaluaciones manuales generan cuellos de botella operativos y una tasa de morosidad (riesgo de impago) que impacta directamente en la rentabilidad de la financiera. La oportunidad comercial radica en explotar el historial transaccional de los clientes para automatizar el proceso de decisión. El propósito es implementar un motor predictivo que identifique patrones ocultos de riesgo, reduciendo las pérdidas por préstamos incobrables y mejorando la velocidad de atención al cliente. El dataset application_train contiene ~307,000 solicitudes con una tasa de incumplimiento de ~8%.

Resumen Ejecutivo

El proyecto abordará la ineficiencia en la evaluación crediticia mediante la creación de un sistema automatizado de puntuación de riesgo. La solución consta de tres partes: (1) consolidar y limpiar el historial de datos relacionales de los clientes, (2) entrenar un modelo de aprendizaje automático optimizado para clases desbalanceadas, y (3) desplegar el modelo mediante una API REST en Express que consume un servicio de inferencia en Python (FastAPI), ambos en contenedores Docker (docker-compose), lista para integrarse al flujo de originación.

Declaración de Alcance

1. Procesamiento de las 7 tablas relacionales (≈ 2.6 GB) y reducción de dimensionalidad mediante selección de variables.
2. Desarrollo y validación técnica del modelo predictivo (ROC-AUC, PR-AUC, KS), con explicabilidad (SHAP), auditoría de sesgos y umbral de decisión por costo esperado.
3. Construcción y contenerización de una API REST para recibir solicitudes y devolver predicciones en tiempo real.

Metas, Objetivos, y beneficios del proyecto

Meta u Objetivo empresarial	Descripción/Medida
Reducción de Pérdidas por Morosidad	Reducir $\geq 7\%$ las pérdidas esperadas por incumplimiento vs. aprobar sin modelo, con el umbral elegido por costo esperado
Automatización Operativa	$\geq 75\%$ de solicitudes resueltas sin intervención humana; latencia p95 < 500 ms
Escalabilidad Tecnológica	Sostener ≥ 10 solicitudes/s con p95 < 500 ms en prueba de carga (margen amplio sobre la demanda esperada)
Equidad y explicabilidad	Top-5 factores por decisión; razón de tasas de aprobación entre grupos ≥ 0.8

Alineación Estratégica / Razón Crítica

Razón	Imprescindible	Que hacer	Me gustaría hacer
Estrategia	Automatizar y optimizar el proceso de evaluación de riesgo crediticio para reducir las pérdidas corporativas por morosidad utilizando minería de datos.		

Mandato	Asegurar que el algoritmo discrimine objetivamente sin sesgos demográficos (cumplimiento regulatorio financiero).		
Directiva		Estandarizar el despliegue del modelo bajo una arquitectura de microservicios (Docker) solicitada por el área de TI.	
Eficiencia			Exponer endpoints documentados (OpenAPI) consumibles por el sistema de originación

Cumplimiento	
Agencia / Proveedor	Detalles del cumplimiento
Autoridad Nacional de Protección de Datos Personales (Ley 29733)	Seudonimización de la información transaccional. El algoritmo utilizará identificadores únicos (SK_ID_CURR) sin exponer nombres o datos de contacto en el pipeline de entrenamiento. El dataset público ya no incluye nombres ni datos de contacto; en producción se aplicaría minimización de datos y no se registrarían datos personales en logs.
Estándares de Seguridad OWASP	Los endpoints de la API REST construida en Express deberán contar con validación de entradas para evitar inyecciones y accesos no autorizados al motor predictivo.

Mandato	
Ley/Resolución	Detalles del mandato
Normativa SBS (Gestión de Riesgo de Crédito)	El modelo de minería de datos debe demostrar una justificación estadística objetiva (explicabilidad del modelo) para denegar o aprobar créditos, asegurando que no existan sesgos discriminatorios hacia los solicitantes. Se realizará una auditoría de sesgos (variables sensibles y proxies) y se documentará en la ficha del modelo.

Directiva	
Gestión	Detalles de la Directiva
Arquitectura de TI y Operaciones	Despliegue estandarizado en contenedores. El modelo de Machine Learning final debe estar encapsulado obligatoriamente

	en un entorno Docker para asegurar su portabilidad y no alterar el ecosistema actual.
Gobierno de Datos Analíticos	Optimización de recursos locales. El procesamiento del dataset relacional de ≈ 2.6 GB debe incluir lectura por bloques, tipos de datos reducidos, agregación previa por cliente y selección de variables para no exceder la capacidad de la memoria RAM del servidor de desarrollo.

Eficiencia	
Problema que se está corrigiendo	Eficiencia ganada (detalles)
Cuello de botella en evaluaciones manuales de crédito.	Aprobación/rechazo automatizado para $\geq 75\%$ de las solicitudes, con revisión humana solo en la zona gris; se liberan horas-hombre del equipo de analistas.

Análisis de alternativas	
Solución Propuesta	Motivo de selección
Modelo propio empaquetado en API REST	Mayor control sobre los datos, escalabilidad técnica completa y costo marginal cercano a cero
Opción Alternativa	Motivo de la no selección
Status Quo (Revisión humana manual)	Inescalable: el costo crece linealmente con el volumen ($8,000 \times 0.5 \text{ h} \times S/10/\text{h} = S/40,000/\text{año}$; $\sim S/200,000$ a 5 años) y no reduce la morosidad
Opción Alternativa	Motivo de la no selección
Contratar API externa (Buró tradicional)	Costo recurrente por consulta y dependencia de un modelo 'caja negra' externo. Con una tarifa hipotética de $S/5$ por consulta: $8,000 \times S/5 \times 5 \text{ años} = S/200,000$, sin control sobre el modelo ni explicabilidad propia

Análisis de costo-beneficio

Este proyecto se desarrolla con fines académicos en el curso de Minería de Datos, sobre el dataset público Home Credit Default Risk (Kaggle). Las cifras de costos y beneficios corresponden a un escenario empresarial hipotético y se basan en los supuestos declarados. El costo real del proyecto académico es marginal (horas del equipo, equipos propios y herramientas open source).

Costo total de propiedad

Concepto	Año 1	Año 2	Año 3	Año 4	Año 5	Total
Infraestructura cloud (Docker + BD)	S/4,000	S/4,000	S/4,000	S/4,000	S/4,000	S/20,000
Software y monitoreo	S/1,000	S/1,000	S/1,000	S/1,000	S/1,000	S/5,000
Operaciones (0.25 FTE soporte TI)	S/15,000	S/15,000	S/15,000	S/15,000	S/15,000	S/75,000

Implementación (1,000 h × S/35)	S/35,000	N/A	N/A	N/A	N/A	S/35,000
Validación, SHAP y auditoría de sesgos	S/6,000	N/A	N/A	N/A	N/A	S/6,000
Seguridad OWASP y revisión legal	S/4,000	N/A	N/A	N/A	N/A	S/4,000
Capacitación de analistas	S/2,000	N/A	N/A	N/A	N/A	S/2,000
Mantenimiento (reentrenamiento y drift)	S/5,000	S/5,000	S/5,000	S/5,000	S/5,000	S/25,000
Subtotal	S/72,000	S/25,000	S/25,000	S/25,000	S/25,000	S/172,000
Contingencia 10%	S/7,200	S/2,500	S/2,500	S/2,500	S/2,500	S/17,200
Total	S/79,200	S/27,500	S/27,500	S/27,500	S/27,500	S/189,200

TABLA DE SUPUESTOS	
Supuesto	Valor
Solicitudes evaluadas / aprobadas por año	8,000 / 5,000 (hipotético)
Monto promedio del crédito	S/ 3,000 (hipotético, independiente de AMT_CREDIT)
Pérdida en caso de incumplimiento	60%
Tasa de incumplimiento	8% (calculada de TARGET en application_train)
Pérdida anual sin modelo	$5,000 \times 8\% \times S/3,000 \times 60\% = S/720,000$
Reducción de pérdidas atribuible al modelo	$7\% \rightarrow S/50,400 \approx S/50,000$
Ahorro de tiempo	$8,000 \times 0.5 \text{ h} \times 75\% \text{ automatizado} \times S/10/\text{h} = S/30,000$
Ingresos adicionales	$100 \text{ créditos} \times S/150 \text{ de margen} = S/15,000$ (neto de falsos positivos)
Costo de un error (para el umbral por costo esperado)	Falso negativo: S/1,800 ($3,000 \times 60\%$); falso positivo: S/150 (margen perdido)
Ramp-up Año 1 / tasa de descuento	50% / 10%

Análisis de costo-beneficio						
	Año 1	Año 2	Año 3	Año 4	Año 5	Total

Tiempo de Personal Ahorrado (Automatización de evaluación)	S/15,000	S/30,000	S/30,000	S/30,000	S/30,000	S/135,000
Costos Evitados (Reducción de créditos incobrables/morosos)	S/25,000	S/50,000	S/50,000	S/50,000	S/50,000	S/225,000
Aumento de Ingresos (Mayor volumen de créditos aprobados rápidos)	S/7,500	S/15,000	S/15,000	S/15,000	S/15,000	S/67,500
Beneficios Financieros Totales	S/47,500	S/95,000	S/95,000	S/95,000	S/95,000	S/427,500

Retorno de Inversión	
Costo total de propiedad (Inversión acumulada a 5 años)	S/189,200
Beneficios totales (acumulados a 5 años)	S/427,500
ROI: (Beneficios totales – Costo total) / Costo total	≈ 126%